

Disciplina: Aprendizagem de Máquina
Período: 2026.1
Professor: César Lincoln Cavalcante Mattos

Lista 2 - Regressão logística e métodos estatísticos

Instruções

- Com exceção dos casos explicitamente indicados, os algoritmos e modelos devem ser implementados do início em qualquer linguagem de programação.
- Pacotes auxiliares (sklearn, matplotlib, etc) podem ser usados somente para facilitar a manipulação dos dados e criar gráficos.
- Para a avaliação do trabalho, recomenda-se o envio de arquivo Jupyter notebook com os códigos executados e os resultados visíveis nas células.

Questão 1

Considere o conjunto de dados disponível em **breastcancer.csv**, organizado em 31 colunas, sendo as 30 primeiras colunas os atributos e a última coluna a saída. Os 30 atributos coletados de exames médicos são usados no diagnóstico do câncer de mama, sendo 1 a classe positiva e 0 a classe negativa. Maiores detalhes sobre os dados podem ser conferidos em https://scikit-learn.org/stable/datasets/toy_dataset.html#breast-cancer-dataset.

- a) Considerando uma validação cruzada em 10 *folds*, avalie modelos de classificação binária nos dados em questão. Para tanto, use as abordagens abaixo:
 - **Regressão logística** (treinado com GD ou SGD);
 - **Análise do discriminante Gaussiano**;
 - **Naive Bayes Gaussiano**;
- b) Para cada modelo criado, reporte valor médio e desvio padrão da **acurácia global** e da **acurácia por classe**.

Questão 2

Considere o conjunto de dados disponível em **vehicle.csv**, organizado em 19 colunas, sendo as 18 primeiras colunas os atributos e a última coluna a saída. Os 18 atributos caracterizam a silhueta de veículos, extraídos pelo método HIPS (Hierarchical Image Processing System). A tarefa consiste em classificar o veículo em 4 classes (bus, opel, saab, e van). Maiores detalhes sobre os dados podem ser conferidos em <https://www.openml.org/search?type=data&sort=runs&id=54>.

- a) Considerando uma validação cruzada em 10 *folds*, avalie modelos de classificação multiclasse nos dados em questão. Para tanto, use as abordagens abaixo:
- **Regressão softmax** (treinado com GD ou SGD);
 - **Análise do discriminante Gaussiano**;
 - **Naive Bayes Gaussiano**;
- b) Para cada modelo criado, reporte valor médio e desvio padrão da **acurácia global** e da **acurácia por classe**.