



UNIVERSIDADE
FEDERAL DO CEARÁ



LogIA

Aprendizagem de Máquina

César Lincoln Cavalcante Mattos

2026

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências

Modelos e parâmetros

- O que são parâmetros?

Modelos e parâmetros

- O que são parâmetros?
 - “Concentram” o que foi aprendido a partir dos dados.

Modelos e parâmetros

- O que são parâmetros?
 - “Concentram” o que foi aprendido a partir dos dados.
- O que são hiperparâmetros?

Modelos e parâmetros

- O que são parâmetros?
 - “Concentram” o que foi aprendido a partir dos dados.
- O que são hiperparâmetros?
 - Definem o “comportamento geral” do modelo (ou do algoritmo de aprendizagem).
- **Ideia:** Um modelo pode “não ter” parâmetros?

Modelos e parâmetros

Modelos paramétricos

- Sumarizam o que foi aprendido a partir dos dados em um **conjunto finito de parâmetros** em quantidade que não depende do número de padrões de treinamento.
- A complexidade/flexibilidade **não cresce** com mais dados.

Modelos e parâmetros

Modelos paramétricos

- Sumarizam o que foi aprendido a partir dos dados em um **conjunto finito de parâmetros** em quantidade que não depende do número de padrões de treinamento.
- A complexidade/flexibilidade **não cresce** com mais dados.

Modelos não-paramétricos

- Admitem um **conjunto ilimitado de parâmetros**, ou seja, sua quantidade depende do número de padrões de treinamento.
- A complexidade/flexibilidade **cresce** com mais dados.

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências



Aprendizado baseado em instâncias

- **Problema:** Como diferenciar laranjas de limões?





Aprendizado baseado em instâncias

- **Ideia:** Mapeamos largura (*width*) e altura (*height*) das frutas.




Aprendizado baseado em instâncias

- **Ideia:** Usamos um classificador linear para separar as frutas.



Aprendizado baseado em instâncias

- **Ideia:** Classificar um novo padrão a partir dos mais próximos?



Aprendizado baseado em instâncias

Modelos baseados em instâncias

- Modelos não-paramétricos.
- Podem não possuir uma etapa separada de treinamento.
- Predições são baseadas nas instâncias de treinamento mais próximas do padrão de teste.
- Precisam armazenar os dados de treinamento para realizar predições.

Aprendizado baseado em instâncias

Modelos baseados em instâncias

- Modelos não-paramétricos.
 - Podem não possuir uma etapa separada de treinamento.
 - Predições são baseadas nas instâncias de treinamento mais próximas do padrão de teste.
 - Precisam armazenar os dados de treinamento para realizar predições.
-
- **Problema:** Como saber se um padrão está próximo de outro?

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências

Nearest Neighbors - Vizinhos mais próximos

- **Ideia:** Distância Euclidiana entre os padrões $\mathbf{x}_i$ e $\mathbf{x}_j$:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}$$

Nearest Neighbors - Vizinhos mais próximos

- **Ideia:** Distância Euclidiana entre os padrões $\mathbf{x}_i$ e $\mathbf{x}_j$:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}$$

Nearest Neighbor (NN) para classificação


- 1 Encontre o padrão $\mathbf{x}_{NN}$ de treinamento mais próximo do padrão de teste $\mathbf{x}_*$:

$$\mathbf{x}_{NN} = \arg \min_{\mathbf{x}_i \in \{\mathbf{x}_1, \dots, \mathbf{x}_N\}} d(\mathbf{x}_i, \mathbf{x}_*).$$

- 2 Retorne a classe y_{NN} associada a $\mathbf{x}_{NN}$.


Nearest Neighbors - Vizinhos mais próximos

- NN cria um **diagrama de Voronoi** e **fronteiras não-lineares**.




Nearest Neighbors - Vizinhos mais próximos

- NN permite a classificação de **dados multi-modais**.




Nearest Neighbors - Vizinhos mais próximos

- **Problema:** NN é muito sensível a **padrões anômalos**.



Nearest Neighbors - Vizinhos mais próximos

- **Ideia:** Considerar mais de um vizinho mais próximo.



Nearest Neighbors - Vizinhos mais próximos

K Nearest Neighbors (KNN) para classificação

- 1 Encontre os K padrões $\mathbf{x}_k, k \in \{1, \dots, K\}$ mais próximo do padrão de teste $\mathbf{x}_*$:

$$\mathbf{x}_{\text{KNN}} = \arg \min_{\mathbf{x}_i \in \{\mathbf{x}_1, \dots, \mathbf{x}_N\}} d(\mathbf{x}_i, \mathbf{x}_*).$$

- 2 Retorne a classe mais comum entre os K padrões encontrados.

KNN - Observações importantes

- **Problema:** Como escolher o valor de K ?
 - Valores **muito altos** de K podem incluir informação de dados muito distantes e **simplificam** a região de decisão.
 - Valores **muito baixos** de K podem ser sensíveis a ruído e tornam a região de decisão **mais complexa**.

KNN - Observações importantes


- **Problema:** Como escolher o valor de K ?
 - Valores **muito altos** de K podem incluir informação de dados muito distantes e **simplificam** a região de decisão.
 - Valores **muito baixos** de K podem ser sensíveis a ruído e tornam a região de decisão **mais complexa**.
- **Ideia:** Avaliar valores para o hiperparâmetro K via grid-search.

KNN - Observações importantes


Grid search para valor de K no modelo KNN

- 1 Separe o conjunto dados em treino, validação e teste;
- 2 Escolha um valor candidato para K;
- 3 Calcule o erro do KNN no conjunto de validação usando os dados de treino;
- 4 Repita os dois passos anteriores para todos os candidatos para K;
- 5 Escolha o valor de K com menor erro na validação;
- 6 Forme um novo conjunto de treino a partir do treino e validação anteriores;
- 7 Calcule o erro nos dados de teste usando o novo conjunto de treinamento e o melhor valor de K encontrado.

KNN - Valor pequeno para K




KNN - Valor alto para K



KNN - K escolhido via grid search

5-NN distância 'euclidean' - error = 29.41%



KNN como um modelo generativo

- Podemos interpretar o KNN para classificação como um modelo generativo.

KNN como um modelo generativo

- Podemos interpretar o KNN para classificação como um modelo generativo.
- Considere uma esfera de volume $V(\mathbf{x})$ em torno do ponto $\mathbf{x}$ crescendo até conter K observações.

KNN como um modelo generativo

- Podemos interpretar o KNN para classificação como um modelo generativo.
- Considere uma esfera de volume $V(\mathbf{x})$ em torno do ponto $\mathbf{x}$ crescendo até conter K observações.
- Sendo $N_c(\mathbf{x})$ o número de exemplos da classe c na esfera e N_c o número total de exemplos da classe c , temos:

$$p(\mathbf{x}|y = c, \mathcal{D}) = \frac{N_c(\mathbf{x})}{N_c V(\mathbf{x})}.$$

KNN como um modelo generativo

- Podemos interpretar o KNN para classificação como um modelo generativo.
- Considere uma esfera de volume $V(\mathbf{x})$ em torno do ponto $\mathbf{x}$ crescendo até conter K observações.
- Sendo $N_c(\mathbf{x})$ o número de exemplos da classe c na esfera e N_c o número total de exemplos da classe c , temos:

$$p(\mathbf{x}|y = c, \mathcal{D}) = \frac{N_c(\mathbf{x})}{N_c V(\mathbf{x})}.$$

- Caso a priori de uma classe seja estimada por $p(y = c|\mathcal{D}) = \frac{N_c}{N}$, a posteriori pode ser obtida via regra de Bayes:

$$p(y = c|\mathbf{x}, \mathcal{D}) = \frac{\frac{N_c(\mathbf{x})}{N_c V(\mathbf{x})} \frac{N_c}{N}}{\sum_{c'} \frac{N_{c'}(\mathbf{x})}{N_{c'} V(\mathbf{x})} \frac{N_{c'}}{N}} = \frac{N_c(\mathbf{x})}{\sum_{c'} N_{c'}(\mathbf{x})} = \frac{N_c(\mathbf{x})}{K}.$$

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências

Nearest Neighbors - Vizinhos mais próximos

K Nearest Neighbors (KNN) para regressão

- 1 Encontre os K padrões $\mathbf{x}_k, k \in \{1, \dots, K\}$ mais próximo do padrão de teste $\mathbf{x}_*$:

$$\mathbf{x}_{\text{KNN}} = \arg \min_{\mathbf{x}_i \in \{\mathbf{x}_1, \dots, \mathbf{x}_N\}} d(\mathbf{x}_i, \mathbf{x}_*).$$


- 2 Retorne uma ponderação das saídas dos K padrões encontrados:

$$\hat{y}_* = \frac{\sum_{k=1}^K \gamma_k y_k}{\sum_{k=1}^K \gamma_k}.$$

- Abordagens comuns para a ponderação das saídas:
 - Uniforme: $\gamma_k = 1, \forall k$.
 - Inversamente proporcional às distâncias: $\gamma_k = \frac{1}{d(\mathbf{x}_k, \mathbf{x}_*)}, \forall k$.


KNN - Exemplo para regressão

2-NN com função 'euclidean' e ponderação 'uniform'. MSE no teste: 1.36e-03.




KNN - Exemplo para regressão

2-NN com função 'euclidean' e ponderação 'distance'. MSE no teste: 1.03e-03.



KNN - Exemplo para regressão

2-NN com função 'manhattan' e ponderação 'distance'. MSE no teste: 9.37e-04.



KNN - Observações importantes

- A função de **distância (ou métrica)** é relevante para o KNN.

KNN - Observações importantes

- A função de **distância (ou métrica)** é relevante para o KNN.
 - Distância **Euclidiana**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}.$$

KNN - Observações importantes

- A função de **distância (ou métrica)** é relevante para o KNN.
 - Distância **Euclidiana**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}.$$

- Distância de **Manhattan**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{d=1}^D |x_{id} - x_{jd}|.$$

KNN - Observações importantes

- A função de **distância (ou métrica)** é relevante para o KNN.
 - Distância **Euclidiana**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}.$$

- Distância de **Manhattan**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{d=1}^D |x_{id} - x_{jd}|.$$

- Distância de **Minkowski**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_p = \left(\sum_{d=1}^D |x_{id} - x_{jd}|^p \right)^{1/p}, p \geq 1.$$

KNN - Observações importantes

- A função de **distância (ou métrica)** é relevante para o KNN.
 - Distância **Euclidiana**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{d=1}^D (x_{id} - x_{jd})^2}.$$

- Distância de **Manhattan**:

$$\|\mathbf{x}_i - \mathbf{x}_j\|_1 = \sum_{d=1}^D |x_{id} - x_{jd}|.$$

- Distância de **Minkowski**:


$$\|\mathbf{x}_i - \mathbf{x}_j\|_p = \left(\sum_{d=1}^D |x_{id} - x_{jd}|^p \right)^{1/p}, p \geq 1.$$

- Distância de **Mahalanobis**:


$$d_M(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^\top \Sigma^{-1} (\mathbf{x}_i - \mathbf{x}_j)},$$

em que Σ é matriz de covariância dos dados de treinamento.


Ilustração da distância de Mahalanobis



KNN - Exemplos




KNN - Exemplos



KNN - Exemplos

5-NN distância 'mahalanobis' - error = 4.55%



KNN - Observações importantes



- **Problema:** Se alguns atributos tiverem magnitude muito maior que outros, eles serão tratados como mais importantes.

KNN - Observações importantes

- **Problema:** Se alguns atributos tiverem magnitude muito maior que outros, eles serão tratados como mais importantes.
 - Normalize os dados.



KNN - Observações importantes

- **Problema:** Se alguns atributos tiverem magnitude muito maior que outros, eles serão tratados como mais importantes.
→ Normalize os dados.
- **Problema:** Maldição da dimensionalidade?




KNN - Observações importantes

- **Problema:** Se alguns atributos tiverem magnitude muito maior que outros, eles serão tratados como mais importantes.
 - Normalize os dados.
- **Problema:** Maldição da dimensionalidade?




- A complexidade do espaço aumenta com mais atributos.
- A quantidade de dados necessários aumenta exponencialmente.
- Custo computacional aumenta com a dimensionalidade.
- Selecione/combine os atributos mais relevantes.

Distância Euclidiana - dados uniformes



Distância Euclidiana - dados Gaussianos



NN e Classificadores Estatísticos

- Relação entre NN e Análise do Discriminante Gaussiano?

NN e Classificadores Estatísticos

- Relação entre NN e Análise do Discriminante Gaussiano?
- Forma geral do ADG:

$$\hat{y}_* = \arg \max_k \left[\log p(C_k) - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k) \right].$$

NN e Classificadores Estatísticos

- Relação entre NN e Análise do Discriminante Gaussiano?
- Forma geral do ADG:

$$\hat{y}_* = \arg \max_k \left[\log p(C_k) - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k) \right].$$

- Considerando $p(C_k)$ e Σ_k iguais para todas as classes:

$$\begin{aligned} \hat{y}_* &= \arg \max_k \left[-\frac{1}{2} (\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k) \right] \\ &= \arg \min_k d_M(\mathbf{x}_*, \boldsymbol{\mu}_k), \end{aligned}$$

em que $d_M(\mathbf{x}_*, \boldsymbol{\mu}_k) = \sqrt{(\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k)}$ é a distância de Mahalanobis.

NN e Classificadores Estatísticos

- Relação entre NN e Análise do Discriminante Gaussiano?
- Forma geral do ADG:

$$\hat{y}_* = \arg \max_k \left[\log p(C_k) - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k) \right].$$

- Considerando $p(C_k)$ e Σ_k iguais para todas as classes:

$$\begin{aligned} \hat{y}_* &= \arg \max_k \left[-\frac{1}{2} (\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k) \right] \\ &= \arg \min_k d_M(\mathbf{x}_*, \boldsymbol{\mu}_k), \end{aligned}$$

em que $d_M(\mathbf{x}_*, \boldsymbol{\mu}_k) = \sqrt{(\mathbf{x}_* - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x}_* - \boldsymbol{\mu}_k)}$ é a distância de Mahalanobis.

- **Classificador do centroide mais próximo:** Equivale a 1-NN em que somente é considerado o centroide das classes.

NN e Métodos de kernel

- Relação entre NN e métodos baseados em kernel?

NN e Métodos de kernel

- Relação entre NN e métodos baseados em kernel?
- Saída de um modelo V-NN para regressão:

$$\hat{y}_* = \frac{\sum_{v=1}^V \gamma_v y_v}{\sum_{v=1}^V \gamma_v},$$

em que $y_v|_{v=1}^V$ são as saídas associadas aos V vizinhos mais próximos $\mathbf{x}_v|_{v=1}^V$. Por exemplo, podemos ter $\gamma_v = \frac{1}{d(\mathbf{x}_*, \mathbf{x}_v)}$.

NN e Métodos de kernel

- Relação entre NN e métodos baseados em kernel?
- Saída de um modelo V-NN para regressão:

$$\hat{y}_* = \frac{\sum_{v=1}^V \gamma_v y_v}{\sum_{v=1}^V \gamma_v},$$

em que $y_v|_{v=1}^V$ são as saídas associadas aos V vizinhos mais próximos $\mathbf{x}_v|_{v=1}^V$. Por exemplo, podemos ter $\gamma_v = \frac{1}{d(\mathbf{x}_*, \mathbf{x}_v)}$.

- Definimos a **função de kernel** $k(\mathbf{x}_*, \mathbf{x}_v) = \gamma_v$ para obter uma **regressão de kernel**:

$$\hat{y}_* = \frac{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v) y_v}{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v)}.$$

NN e Métodos de kernel

- Relação entre NN e métodos baseados em kernel?
- Saída de um modelo V-NN para regressão:

$$\hat{y}_* = \frac{\sum_{v=1}^V \gamma_v y_v}{\sum_{v=1}^V \gamma_v},$$

em que $y_v|_{v=1}^V$ são as saídas associadas aos V vizinhos mais próximos $\mathbf{x}_v|_{v=1}^V$. Por exemplo, podemos ter $\gamma_v = \frac{1}{d(\mathbf{x}_*, \mathbf{x}_v)}$.

- Definimos a **função de kernel** $k(\mathbf{x}_*, \mathbf{x}_v) = \gamma_v$ para obter uma **regressão de kernel**:

$$\hat{y}_* = \frac{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v) y_v}{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v)}.$$

- Note que poderíamos usar todos os dados disponíveis na expressão acima, ponderados pelo kernel.

NN e Métodos de kernel

- Relação entre NN e métodos baseados em kernel?
- Saída de um modelo V-NN para regressão:

$$\hat{y}_* = \frac{\sum_{v=1}^V \gamma_v y_v}{\sum_{v=1}^V \gamma_v},$$

em que $y_v|_{v=1}^V$ são as saídas associadas aos V vizinhos mais próximos $\mathbf{x}_v|_{v=1}^V$. Por exemplo, podemos ter $\gamma_v = \frac{1}{d(\mathbf{x}_*, \mathbf{x}_v)}$.

- Definimos a **função de kernel** $k(\mathbf{x}_*, \mathbf{x}_v) = \gamma_v$ para obter uma **regressão de kernel**:

$$\hat{y}_* = \frac{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v) y_v}{\sum_{v=1}^V k(\mathbf{x}_*, \mathbf{x}_v)}.$$

- Note que poderíamos usar todos os dados disponíveis na expressão acima, ponderados pelo kernel.
- **Kernel ridge regression:** $\hat{y}_* = \mathbf{k}(\mathbf{x}_*, \mathbf{X}) (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$.

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências

Tópicos adicionais

- Técnicas para cálculo rápido de distâncias.
 - “Truques” matriciais.
 - Exemplo para distância Euclidiana ao quadrado entre o vetor $\mathbf{x}$ e a matriz $\mathbf{X}$ (em Python/Numpy):
$$\text{dist2} = -2 * \mathbf{x} @ \mathbf{X.T} + (\mathbf{x}^{**2}).\text{sum}(\text{axis}=1) + (\mathbf{X}^{**2}).\text{sum}(\text{axis}=1)$$
 - Uso de implementações otimizadas, como o framework livre FAISS: <https://github.com/facebookresearch/faiss>
 - Uso de dados estruturados em árvores.
 - Métodos aproximados, como locality-sensitive hashing (LSH).
- Kernel KNN.
- Metric learning
 - Neighborhood components analysis (NCA).
 - Large margin nearest neighbor (LMNN).

Agenda

- ① Modelos e parâmetros
- ② Aprendizado baseado em instâncias
- ③ Vizinhos mais próximos para classificação
- ④ Vizinhos mais próximos para regressão
- ⑤ Tópicos adicionais
- ⑥ Referências

Referências bibliográficas

- **Cap. 1** - MURPHY, Kevin P. **Machine learning: a probabilistic perspective**, 2012.
- **Cap. 16** - MURPHY, Kevin P. **Probabilistic Machine Learning: An Introduction**, 2021.
- **Cap. 2** - BISHOP, C. **Pattern recognition and machine learning**, 2006.